

Quem recebeu o dinheiro da cota parlamentar?

Sete anos de nota fiscal, 1,56 milhão de linhas, domínio público. Vou responder três vezes nos próximos 35 minutos. As duas primeiras respostas estão erradas, e nenhuma delas dá erro.

O DADO

Uma nota fiscal por linha, sete arquivos.

A **CEAP** é a verba mensal de cada deputado. Ele gasta, presta contas, e a Câmara publica o CSV inteiro — um por ano, desde bem antes de 2019.

Ano-2019.csv ... Ano-2025.csv · 538 MB · 32 colunas · **1.560.019**

lançamentos

O JEITO QUE A GENTE COMEÇA

```
analise.py

import pandas as pd

df = pd.read_csv("Ano-2025.csv", sep=";", encoding="latin-1")

top = (df.groupby("txtFornecedor")["vlrDocumento"]
       .sum()
       .sort_values(ascending=False)
       .head(10))

print(top)
```

Oito linhas, 40 segundos, nenhuma dependência além do pandas. Eu escrevo assim, você escreve assim, e na maior parte das vezes está tudo bem.

A SAÍDA, NOS SETE ANOS

python analise.py

TAM	R\$ 116.350.000
GOL	R\$ 52.850.000
Cia Aérea - TAM	R\$ 43.430.000
AZUL	R\$ 37.530.000
Cia Aérea - GOL	R\$ 35.240.000
PANTANAL VEÍCULOS	R\$ 18.780.000

ERRADO

Primeiro e terceiro lugar são a mesma companhia aérea, escrita de dois jeitos. Segundo e quinto também. O script rodou até o fim, sem aviso nenhum.

DOIS PROBLEMAS, EMPILHADOS

Nem a soma está certa, nem a pergunta estava bem feita.

A **soma** quebrou porque o nome do fornecedor é texto livre: a mesma empresa entra com grafias diferentes e vira duas linhas.

A **pergunta** quebrou porque companhia aérea não é fornecedora de deputado. É o **SIGEPA**, o sistema de passagens da própria Câmara: o bilhete sai por lá e a companhia cai na planilha.

Quantos lançamentos não têm CNPJ, ano a ano.

spark-sql – silver, agrupado por ano

ANO	LANÇAMENTOS	SEM CNPJ	%
2019	289.830	4.448	1,5%
2020	167.132	17.234	10,3%
2021	218.765	43.487	19,9%
2022	209.556	46.992	22,4%
2023	232.745	56.943	24,5%
2024	232.925	58.164	25,0%

A Câmara foi movendo o voo de "fornecedor com CNPJ" para "SIGEPA, sem CNPJ". Quem escreveu o script em 2019 não escreveu nada errado. O chão é que andou.

Um pipeline não erra menos que um script. Ele erra num lugar onde dá para ver.

O que vem agora são quatro erros que eu cometi montando esta aula, e o que exatamente pegou cada um deles.

DEFEITO QUE NÃO É DEFEITO


56.912 linhas com valor negativo.

São estornos: dinheiro devolvido. Somados junto com o resto, abatem o gasto de quem não gastou.

Apagar resolveria a soma e perderia a informação. Na silver eles viram uma coluna `eh_estorno`, ficam onde estão, e cada pergunta decide se conta com eles. A gold, que responde "quanto saiu", conta sem.

A MESMA EMPRESA, SETENTA VEZES

Setenta fornecedores que são um posto só.



 **CASCOL – R\$ 5.522.621 nos sete anos – uma raiz de CNPJ**

Nenhuma grafia isolada era grande o bastante para aparecer no pódio. Juntas, entram em décimo.

UMA ASSINATURA DE CHATGPT, DOIS UNIVERSOS

2023

0000000000000010

ChatGPT Plus Subscription

R\$ 98,93, com R\$ 56,06 de glosa
categoria: manutenção de escritório

2025

62531071000178

chatGPT

R\$ 999,90
categoria: manutenção de escritório

O documento da esquerda tem 14 dígitos e passa em qualquer validação de CNPJ. Ele é uma gaveta interna da Câmara, e naquele mesmo ano a mesma assinatura também foi lançada como **assinatura de publicações**, por R\$ 105,03.

ONDE O CONCERTO VAI MORAR

CAMADA 1

bronze

Como a Câmara publicou. Tudo texto, nada consertado. 1.560.019 linhas.

CAMADA 2

silver

Tipos certos e sete colunas de defeito marcado. Nenhuma linha some.

CAMADA 3

gold

Uma tabela por pergunta. 55.672 empresas, somadas pela raiz do CNPJ.

Guardar o bronze cru custa 5 GB e parece desperdício até a primeira vez que a regra de limpeza está errada. Aí ele é o que permite refazer sem pedir o arquivo de novo — e a Câmara **republica os CSVs com correções**, então o arquivo de hoje não é o de ontem.

A MESMA PERGUNTA, NAS DUAS PONTAS

spark-sql – container spark-master

```
spark-sql> SELECT txtFornecedor, sum(vlrDocumento) t  
              FROM delta.`s3a://lake/bronze` WHERE numAno=2025 GROUP BY 1 ORDER BY 2 DESC LIMIT 3;
```

```
TAM 16.402.463,26    GOL 6.052.550,88    AZUL 4.696.245,04
```

```
spark-sql> SELECT fornecedor, total  
              FROM fornecedores WHERE ano_ref=2025 ORDER BY total DESC LIMIT 3;
```

```
FACEBOOK 3.251.951,87    PANTANAL 3.227.314,77    VIVO 1.591.715,84
```

Mesmo arquivo, mesma pergunta, nenhum nome repetido entre as duas listas.

A RESPOSTA, EM 2025

R\$ 3,25 mi

FACEBOOK SERVIÇOS ONLINE DO BRASIL

Nos sete anos somados a lista volta a começar com companhia aérea, e dessa vez está certo: até 2022 a Câmara lançava o voo **com** CNPJ. A resposta depende do ano porque o dado mudou de forma, e é por isso que o ano é uma partição e não um filtro solto no meio de um script.

QUATRO ERROS MEUS, E O QUE PEGOU CADA UM

o que aconteceu montando esta aula

O ERRO

regra de glosa acusou 53.112 linhas boas

a mesma empresa com nome diferente a cada execução

soma saindo como 4.99577E7 na tela

R\$ 15,1 mi de um fornecedor que não existe

O QUE PEGOU

o relatório conta, não filtra

rodar duas vezes e comparar

tipo decimal na gold

consultar a gold antes de crer

O quarto ia para este slide. Ramal, celular funcional e Correios compartilham a raiz **00000000**, viraram uma empresa só e apareceram em quarto lugar. Os catorze dígitos batem, inclusive os verificadores. Formato válido e significado válido são coisas diferentes.

0 ERRO CONTINUA CONSULTÁVEL

```
spark-sql -- DESCRIBE HISTORY
```

VERSÃO	OPERAÇÃO	LINHAS	O QUE ERA
0	WRITE	209.079	sem multiLine – 13 linhas partidas
1	WRITE	209.066	com multiLine – correto

```
spark-sql> SELECT count(*) FROM delta.`s3a://lake/bronze` VERSION AS OF 0;  
209079
```

Treze linhas têm quebra de linha dentro de um campo entre aspas, e dois motores honestos discordam sobre isso por padrão. O que a tabela Delta acrescenta é que a contagem errada não foi sobrescrita: ela virou a versão 0, e dá para voltar nela agora.

O QUE IMPEDE A VOLTA

21 testes, e dois deles têm nome de cicatriz.

```
pytest /opt/testes
```

```
PASSED test_estorno_nao_conta_como_glosa_maior
```

```
PASSED test_raiz_zerada_nao_e_empresa
```


```
PASSED test_raiz_de_verdade_nao_e_confundida
```

```
...
```

```
21 passed in 11.09s
```

Rodam sem MinIO e sem cluster, numa SparkSession local, em 11 segundos. O que eles testam não é o Spark: é se a regra de negócio ainda significa o que eu quis dizer.

A SALA DE MÁQUINAS – TUDO EM CONTAINERS



o Spark não guarda o dado. derrube os três containers dele e o lake continua inteiro.

O MESMO DESENHO, COM O NOME QUE ELE TEM NA NUVEM

PROCESSAMENTO

Apache Spark

NO SEU DOCKER

EMR · Dataproc · Databricks · Synapse

O MESMO APACHE SPARK, OPERADO POR OUTRA PESSOA

ARMAZENAMENTO

MinIO

NO SEU DOCKER

Amazon S3 · Google Cloud Storage · Azure Blob

A MESMA API. VOCÊ TROCA UMA LINHA DE CONFIGURAÇÃO.

Delta Lake é o mesmo formato dos dois lados. Ele é aberto, e não muda quando você paga.

QUANDO CADA UM FAZ SENTIDO

NO SEU DOCKER

Bom quando...

- você está aprendendo e quer quebrar sem medo
- o dado cabe confortavelmente numa máquina
- o ciclo curto importa: subiu, errou, refez em minutos
- o dado não pode sair da sua rede

NA NUVEM

Bom quando...

- o dado não cabe mais numa máquina só
- você precisa de 200 máquinas por 20 minutos
- o time é pequeno e o plantão não pode ser você
- outras equipes precisam do mesmo dado, com governança

É o mesmo Apache Spark e o mesmo Delta Lake dos dois lados. O que muda é quem opera a infraestrutura.

PARA LEVAR PARA CASA

O script do slide 3 continua certo. Ele só precisava de um lugar para morar.

Tudo que você viu é software aberto — MinIO, Apache Spark, Delta Lake, Docker — e um CSV público da Câmara. Roda no seu laptop hoje e sobe na nuvem no dia em que o dado crescer, sem reescrever a regra.

```
make subir · make pipeline
```